Fundação Universidade Federal do ABC
Pró reitoria de pesquisa
Av. dos Estados, 5001, Santa Terezinha, Santo André/SP, CEP 09210-580
Bloco L, 3ºAndar, Fone (11) 3356-7617
iniciacao@ufabc.edu.br

Relatório Parcial de Iniciação Científica
submetido para avaliação no Edital:
01/2025

Nome do aluno: Thiago Fernandes Dias

Assinatura do aluno:

Nome do orientador: Paulo Henrique Pisani

Assinatura do orientador:

Nome do coorientador: Francisco de Assis Zampirolli

Assinatura do coorientador:

Título do projeto: Avaliação de técnicas de extração de características para reconhecimento de usuários pela impressão digital

Palavras-chave do projeto: biometria; aprendizado de máquina; classificação

Área do conhecimento do projeto: Ciências Exatas e da Terra; Ciência da Computação; Metodologia e Técnicas da Computação

Bolsista: Sim, CNPq

Santo André

2026

Resumo

O objetivo deste projeto é avaliar diferentes métodos de extração de características de impressões digitais voltados para a verificação biométrica de usuários. A metodologia do projeto estabelece o uso de conjuntos de dados públicos, como os das competições FVC (Fingerprint Verification Competition) e da Neurotechnology, e métricas de desempenho como FMR, FNMR, EER e acurácia balanceada. Até o momento, o trabalho desenvolveu uma revisão bibliográfica e iniciou a experimentação utilizando um modelo pré-treinado baseado na arquitetura *DeepPrint*, que extrai das impressões digitais uma representação de tamanho fixo, que pode ser usada em algoritmos de classificação baseados em distâncias. O modelo foi testado utilizando conjunto de dados FVC2004. Como trabalhos futuros, outras técnicas baseadas em Aprendizado de Máquina serão avaliadas nos demais conjuntos de dados da FVC.

Sumário

1 Introdução **4**

2 Fundamentação teórica **5**

2.1 Biometria por Impressão Digital 5

2.2 Formas de representação de impressões digitais 6

2.3 Extração de características de digitais 6

3 Objetivos **9**

4 Metodologia **9**

4.1 Conjuntos de dados 10

4.1.1 *Fingerprint Verification Competition* (FVC) 10

4.1.2 Neurotechnology 10

4.2 Métricas 10

4.3 Algoritmos 11

4.3.1 Arquitetura do *DeepPrint* 12

4.4 Experimentos 13

4.4.1 Treinamento do DeepPrint 13

4.4.2 Testes com o modelo pré-treinado 14

5 Resultados e discussão dos resultados **14**

6 Conclusões e perspectivas de trabalhos futuros **14**

REFERÊNCIAS **17**

1 Introdução

A Biometria é uma forma de identificação que se baseia nas características físicas e comportamentais das pessoas, como íris, impressões digitais e voz. Sistemas biométricos operam sobre a premissa de que tais características são únicas de cada pessoa, e, se puderem ser extraídas através de sensores, podem ser convertidas para representações numéricas e processadas por algoritmos de reconhecimento de padrões (JAIN; FLYNN; ROSS, 2007). Como os dados biométricos são particulares a cada pessoa eles podem ser usados como forma de autenticação e de forma mais segura do que o uso de senhas (JAIN; ROSS; PANKANTI, 2006).

Neste projeto, será dado o enfoque na vertente física, em particular, na biometria através de impressões digitais. Essa modalidade biométrica se baseia nos padrões de pequenas elevações e depressões na pele das pontas dos dedos (MALTONI et al., 2022). Os usuários são então reconhecidos com base nas diferenças nesses padrões.

Conforme definido por Jain, Ross e Prabhakar (2004), sistemas biométricos são sistemas de reconhecimento de padrões que extraem características de dados biométricos e então comparam as características extraídas com uma referência biométrica em um banco de dados. Nesse sentido, Maltoni et al. (2022) explica que, para a autenticação através de digitais, a representação das características extraídas das imagens é um problema fundamental da verificação de digitais.

Como não há a garantia de que as imagens da digital de um mesmo dedo serão exatamente iguais em termos de intensidade de pixel, orientação e formato, há a necessidade de se extrair características a partir das quais seja possível diferenciar digitais com uma boa acurácia e que sejam invariantes para uma dada digital. Somente assim o uso de digitais em sistemas de autenticação se tornariam viáveis.

O objetivo deste trabalho é avaliar diferentes técnicas de extração de características para reconhecimento de usuários pela impressão digital. As demais seções do projeto estão organizadas da seguinte forma: na Seção 2, são introduzidos conceitos sobre reconhecimento de usuários pela impressão digital e a revisão bibliográfica realizada; na Seção 3, são definidos os objetivos; na Seção 4, a metodologia é descrita, incluindo conjuntos de dados e métricas; na Seção 5 são exibidos os resultados obtidos e na Seção 6 é feita a conclusão do relatório.

2 Fundamentação teórica

Esta seção apresenta algumas constatações sobre a pesquisa na área de impressões digitais e técnicas de extração de características.

2.1 Biometria por Impressão Digital

O termo "Impressão Digital" no contexto de biometria por digitais se refere ao padrão de pequenos cumes e vales que podem ser observados na ponta dos dedos das pessoas. Ao longo da evolução da raça humana o desenvolvimento de digitais está relacionado à capacidade de segurar objetos com as mãos. O padrão específico de cumes e vales, assim como outras características do corpo, é definido por fatores genéticos e ambientais (MALTONI et al., 2022).

O reconhecimento de que as impressões digitais são únicas para cada dedo de cada pessoa ocorreu em 1880 com base em observações experimentais de Henry Fauld (MOENSSENS, 1971). Em 1993, a unicidade de impressões digitais foi reconhecida por entidades governamentais do Reino Unido, e foi determinado que as digitais de criminosos seriam coletadas no momento da prisão. Dessa forma, os especialistas em investigação forense poderiam identificar criminosos com base em manchas de impressões digitais deixadas na cena de crime, chamadas de impressões digitais latentes. A partir disso, órgãos de segurança pública investiram intensamente em pesquisas sobre impressões digitais e no treinamento de especialistas em reconhecimento de digitais (SCOTT, 1951).

Conforme explica Maltoni et al. (2022), apesar dos esforços para tornar mais eficiente o processo manual de identificação por impressões digitais, o aumento da demanda tornou esse método inviável. O sistema de classificação manual era ineficiente, o treinamento de novos profissionais capazes de empregá-lo era demorado e a comparação visual de impressões digitais era cansativa e lenta. Por isso, os órgãos de segurança pública começaram a investir em soluções eletrônicas e automatizadas, o que levou ao desenvolvimento dos *Automated Fingerprint Identification Systems* (AFIS) ou Sistemas Automatizados de Identificação de Impressões Digitais.

Inicialmente usados por forças de segurança, esses sistemas hoje também são aplicados em diversas áreas não forenses devido ao aumento das preocupações com segurança e fraudes de identidade. Por exemplo, sistemas biométricos tem sido adotados em *Internet Banking* e autenticação de usuários em dispositivos móveis. Nesse contexto, as digitais são coletadas com sensores especializados que geram imagens das digitais, que são processadas a fim de se obter

uma forma de representação que pode ser usada para verificação (MALTONI et al., 2022).

2.2 Formas de representação de impressões digitais

Maltoni et al. (2022) enfatiza que uma boa representação de uma impressão digital deve: (*i*) conter informações que possibilitem distinguir entre duas amostras; (*ii*) ser extraída de forma rápida e fácil; e (*iii*) ser compacta, de modo a poder ser armazenada em sistemas biométricos com pouca capacidade. Representações baseadas em imagens, em geral, não são adequadas devido às variações de iluminação, resolução, qualidade e aos ruídos provocados por cicatrizes ou outras lesões nos dedos, especialmente em pessoas que realizam trabalhos manuais com frequência.

O autor supracitado divide os atributos que podem ser extraídos de uma impressão digital em três níveis diferentes:

- **Nível 1**: também chamado de nível global, há atributos como o padrão das curvaturas das linhas nas imagens, delimitadas pelos cumes e vales da impressão digital. A partir dela podem ser determinados os "pontos singulares", que são os centros das curvaturas dessas linhas (LEVI; SIROVICH, 1972). As imagens de orientação e frequência e o formato da digital (que serão definidos posteriormente) também são considerados atributos de escopo global;

- **Nível 2**: são as características de escopo local, que exigem uma análise em uma escala menor da impressão digital. Dentre elas as que são mais facilmente observadas em sensores convencionais são as *bifurcações de cume*, onde um cume se divide em dois, e *terminações de cume*, onde um cume termina em um vale. Tais características são chamadas de *minúcias*, e são normalmente definidas pela sua posição na impressão digital e orientação (ângulo);

- **Nível 3**: são atributos relacionados aos próprios cumes, como formato, largura, contorno e a posição e o formato dos poros excretores de suor. Essas características são altamente distintivas, porém só podem ser extraídas de impressões digitais com alta resolução (acima de 1000 dpi).

2.3 Extração de características de digitais

Com o objetivo de selecionar os métodos que seriam avaliados neste projeto foi feita uma revisão bibliográfica sobre artigos que descreviam métodos de extração que, preferencialmente, utilizas-

sem algoritmos de Aprendizado de Máquina e que utilizassem conjuntos de dados públicos para treinamento e teste dos modelos, para facilitar reprodutibilidade.

Na Tabela 1 há alguns dos artigos lidos e as técnicas de extração de características propostas.

Tabela 1 – Revisão Bibliográfica

Referência	**Conjunto de dados**	**Métricas**	**Código aberto**
Cappelli, Ferrara e Maltoni (2010)	FVC2006	EER, FMR	Sim
Nguyen, Cao e Jain (2018)	FVC2002, FVC2004, NIST SD27	F1 Score, Precisão, Recall	Sim
Engelsma, Cao e Jain (2021)	Privado, NIST SD4, NIST SD14, FVC2004	*Acc*, FMR	Sim
Ezeobiejesi e Bhanu (2017)	NIST SD27, WVU, IIITD	MDR, FDR, SA	Não
Tang, Gao e Feng (2017)	Privado, NIST SD27	Recall, Precisão, F1 Score	Não
Tang et al. (2017)	Privado, NIST SD27	Precisão, Recall	Sim
Zhang, Xin e Feng (2019)	Privado, FVC2002, FVC2004	EER, FMR, FNMR	Não
Li et al. (2019)	Privado, NIST SD4, NIST SD14	Top-K ER	Não

Em (CAPPELLI; FERRARA; MALTONI, 2010) foi proposta uma forma de representação chamada de *Minutia Cylinder-Code*. Ela é baseada em estruturas de dados 3D, os cilindros, que codificam os ângulos das minúcias e as distâncias entre elas.

Nguyen, Cao e Jain (2018) criaram a *MinutiaeNet*, que é um modelo composto por duas redes neurais convolucionais, a *CoarseNet*, para estimar os mapas de *scores* de minúcias com base em informações de domínio, e a *FineNet*, para refinamento dos *scores*.

Engelsma, Cao e Jain (2021) introduziram a *DeepPrint*, uma CNN que extrai uma representação de tamanho fixo utilizando alinhamento por Transformadores Espaciais (JADERBERG et al., 2016), informações de domínio e Aprendizado Multitarefa (CARUANA; PRATT; THRUN, 1997).

Ezeobiejesi e Bhanu (2017) criaram uma técnica para segmentação de impressões digitais utilizando uma rede neural profunda composta por pilhas de Máquinas de Boltzmann Restritas

(*Restricted Boltzmann Machine*, RBM) para delimitar impressões digitais latentes classificando seções das imagem entre duas classes: "impressão digital" e "*background*".

Tang, Gao e Feng (2017) utilizaram uma Rede Neural Totalmente Convolucional (*Fully Convolutional Network*, FCN) para selecionar seções da imagem com uma probabilidade alta de conter uma minúcia. As seções selecionadas serviram de entrada para uma CNN dedicada a classificação propriamente dita, que também calculava a orientação das minúcias.

Tang et al. (2017) criaram a *FingerNet* é uma CNN que extrai um mapa de minúcias utilizando informações de domínio como orientação dos cumes e segmentação, que também são extraídos pela rede, além de realçar as digitais.

Zhang, Xin e Feng (2019) utilizaram duas CNNs baseadas na arquitetura ResNet (SZEGEDY et al., 2017), uma que extrai uma representação de tamanho fixo e outra um mapa de minúcias. A verificação é feita através de cálculo de distâncias de ambas as representações.

Li et al. (2019) desenvolveram de uma FCN que extraí uma representação de tamanho fixo com base em atributos globais e locais. O treinamento é feito utilizando porções da imagem (chamados de "*patches*") centrados nas minúcias. Na fase de indexação, a rede recebe a imagem completa da digital, e utiliza *Global Average Pooling* (GAP) para agregar todas as informações locais extraídas pela FCN em uma única representação global.

Dentre técnicas que utilizam redes neurais profundas para extração de características há duas formas de representação que se destacaram: o mapa de minúcias, que é uma representação de tamanho variável que armazena a posição de cada minúcia e sua orientação, e uma representação de tamanho fixo, que são os pesos das camadas totalmente conectadas das CNN imediatamente antes do cálculo das probabilidades de cada uma das classes (normalmente de qual dedo a digital foi coletada). Conforme explica Engelsma, Cao e Jain (2021), a vantagem das representações de tamanho fixo são a necessidade de menos poder computacional para verificação, que pode ser feita por um simples cálculo de distância e comparação com um limiar de corte, e de espaço para armazenamento.

Outro aspecto que esteve presente nos experimentos foi a utilização de informações de domínio, que são as características intrínsecas das digitais (MALTONI et al., 2022). Quando essas informações são incluídas no treinamento dos modelos ou aprendidas em conjunto com as representações o seu desempenho tende a ser superior do que utilizar atributos mais abstratos, como apenas a textura das digitais.

Nos experimentos desenvolvidos nos artigos foram utilizados conjuntos de dados públicos

e privados, com diferentes características. Por exemplo, Zhang, Xin e Feng (2019) utilizou impressões digitais parciais de alta resolução, o que torna viável a inclusão de informações sobre os atributos de Nível 3 na rede neural. Já em (TANG; GAO; FENG, 2017) foram utilizadas impressões digitais latentes, que são coletadas em cenas de crimes quando pessoas tocam em objetos (MALTONI et al., 2022)

Destas técnicas foram encontradas implementações da MCC, *MinutiaeNet*, *FingerNet* e *DeepPrint*, e um modelo pré-treinado do *DeepPrint* disponibilizado por Rohwedder et al. (2023). Como o MCC é uma representação que não envolve aprendizado, ela não será avaliada neste trabalho.

3 Objetivos

Este projeto tem o objetivo de **avaliar diferentes técnicas de extração de características para o reconhecimento de usuários pela impressão digital**. Para isso, será estudado o processo de extração de características a partir de imagens de impressão digital e sua representação.

Os objetivos específicos do projeto são:

- Selecionar conjuntos de dados de impressão digital (ver Seção 4);
- Selecionar técnicas de extração de características para reconhecimento de usuários pela impressão digital;
- Realizar experimentos comparando as diferentes técnicas de extração de características;
- Avaliar as técnicas de extração de características sob diversos aspectos.

4 Metodologia

Nesta seção será apresentada a metodologia de pesquisa e experimentação. Na Seção 4.1 serão descritos os conjuntos de dados utilizados e nas Sessões 4.2, 4.3 e 4.4 e serão expostos detalhes sobre as métricas para avaliação, técnicas de extração utilizadas e os experimentos realizados, respectivamente.

4.1 Conjuntos de dados

Foi feita uma pesquisa por conjuntos de dados públicos para a realização de treinamento e teste de modelos para extração de características. A seguir, uma breve descrição sobre os conjuntos de dados encontrados.

4.1.1 *Fingerprint Verification Competition* (FVC)

Foram realizadas algumas competições organizadas por pesquisadores da *University of Bologna* para avaliação de sistemas de reconhecimento de usuários pela impressão digital. As partes A e B dos conjuntos de dados utilizados nas edições de 2000, 2002 e 2004 foram disponibilizadas publicamente como um material adicional da publicação de Maltoni et al. (2022).

Para cada ano da competição, há 4 conjuntos de dados, sendo 3 deles coletados com diferentes sensores e um quarto conjunto de impressões digitais sintéticas geradas através do software SFinGe (MALTONI et al., 2022). Cada um deles foi separados nas partes "A", com imagens de 100 dedos, e "B", com imagens de 10 dedos. Para cada dedo há 8 impressões digitais, totalizando 880 imagens em cada conjunto. Portanto, no total, o FVC possui $880 \times 4 \times 3 = 10560$ imagens.

4.1.2 Neurotechnology

A empresa Neurotechnology disponibilizou dois conjuntos de imagens de impressão digital, que podem ser acessados pelo site [1]. O primeiro conjunto de dados possui imagens de 51 dedos com 8 impressões cada, totalizando 408 imagens capturadas com o leitor *Cross Match Verifier 300*. O segundo possui imagens de 65 dedos com 8 impressões cada, totalizando 520 imagens coletadas com o leitor *DigitalPersona U.are.U 4000*.

4.2 Métricas

Esta seção descreve algumas métricas usadas na literatura que serão usadas para avaliação dos resultados nos experimentos realizados neste projeto de pesquisa. Essas métricas são: FMR, FNMR e acurácia balanceada (Precise Biometrics, 2014; FERLINI et al., 2021). Uma breve descrição dessas métricas é apresentadas a seguir:

- FMR (*False Match Rate*, Taxa de falsa correspondência): percentual de tentativas de impostores que foram aceitas como genuínas, definida como

[1] <https://www.neurotechnology.com/download.html>

$$FMR = \frac{\textit{número de tentativas de impostores aceitas}}{\textit{total de tentativas de impostores}}. \tag{1}$$

Uma taxa relacionada é a FAR (*False Acceptance Rate*), que tem significado similar, mas considera também taxa em que o sistema biométrico falha ao obter uma amostra biométrica. Essa taxa é conhecida como FTA (*Failure to Acquire Rate*).

- FNMR (*False Non-match Rate*, Taxa de falsa não-correspondência): percentual de tentativas genuínas que foram rejeitadas como impostoras pelo sistema, definida como

$$FNMR = \frac{\textit{número de tentativas genuínas rejeitadas}}{\textit{total de tentativas de usuários genuínos}}. \tag{2}$$

Uma métrica relacionada é a FRR (*False Rejection Rate*), que tem um significado similar, mas considera também a FTA.

- Acurácia balanceada: média do acerto para cada classe (genuíno e impostor). Essa métrica pode ser obtida a partir do cálculo da (HTER - *Half Total Error*, Metade do erro total)

$$HTER = \frac{FNMR + FMR}{2}, \tag{3}$$

definida como a média entre FNMR e FMR (ROY et al., 2022). A partir da HTER, então é obtida a acurácia balanceada,

$$BAcc = 1 - HTER. \tag{4}$$

- EER (*Equal Error Rate, Taxa de erro igual*): ponto em que a FMR é igual a FNMR, em um determinado limiar de corte.

4.3 Algoritmos

Para os experimentos iniciais foram feitas buscas por repositórios com código-fonte disponíveis publicamente ou modelos pré-treinados que poderiam ter sido disponibilizados pelos autores dos artigos lidos na revisão bibliográfica. Até o momento foram feitos experimentos com o modelo DeepPrint implementado por Rohwedder et al. (2023).

4.3.1 Arquitetura do *DeepPrint*

Engelsma, Cao e Jain (2021) desenvolveram uma Rede Neural Convolucional (*Convolutional Neural Network* ou CNN) que "aprende" a extrair uma representação de tamanho fixo (um vetor) a partir de uma impressão digital. Como entrada a rede recebe uma imagem de tamanho 448×448 em escala de cinza (cada pixel assume um valor de 0 a 255) e passa primeiro pelo módulo de alinhamento. O módulo de alinhamento utiliza uma rede neural de transformação espacial (JADERBERG et al., 2016) para fazer com que a impressão digital na imagem fique no centro.

Em seguida, a imagem passa por uma rede base, que consiste na parte inicial da arquitetura *Inception* v4 (SZEGEDY et al., 2017), isso é, sem os módulos *Inception*. Neste ponto a rede é bifurcada em duas novas redes. A primeira completa a arquitetura da *Inception* v4 incluindo os módulos A, B e C, conforme descrito por Szegedy et al. (2017). O objetivo desta sub-rede é aprender a identificar impressões digitais com base apenas em sua textura (orientação dos cumes, formato da digital, etc), classificados por Maltoni et al. (2022) como atributos de nível 1, de nível global.

A segunda sub-rede possui um módulo A da arquitetura *Inception* v4, e também aprende a identificar impressões digitais com base em atributos globais. Entretanto, ela possui uma tarefa secundária de localizar as minúcias da digital e suas orientações, criando um mapa de minúcias, através de uma segunda CNN que também possui como base o módulo A. Esse compartilhamento de parâmetros entre a rede que classifica com base na textura, e a rede aprende a gerar o mapa de minúcias, classificado por Maltoni et al. (2022) como um atributo de nível 2, local e mais específico, melhora a capacidade de generalização da rede. Isso é uma técnica conhecida como Aprendizado Multitarefa (CARUANA; PRATT; THRUN, 1997).

Após a imagem de entrada passar por todas as camadas convolucionais, ela passa por camadas totalmente conectadas, e, em seguida, por funções de ativação *softmax*, para calcular a probabilidade de ela pertencer a cada uma das classes, em ambas as sub-redes. Com isso, os 96 pesos das camadas totalmente conectadas são concatenados para formarem um vetor de 192 dimensões. Em seguida os valores reais dos pesos são convertidos para inteiros utilizando normalização por mínimos e máximos. Dessa forma, podem ser usadas distâncias e um limiar de corte para verificação.

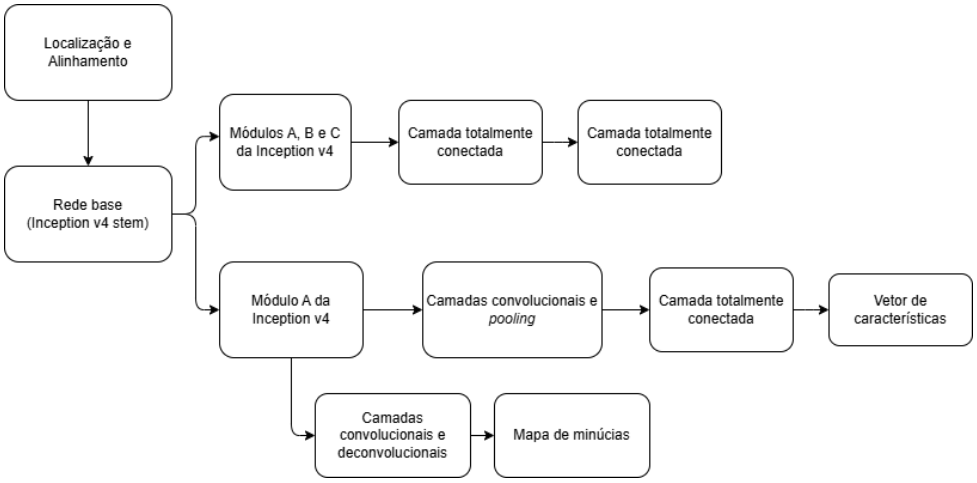

Figura 1 – Arquitetura da rede neural *DeepPrint*

4.4 Experimentos

Até o momento foram realizados experimentos com um modelo pré-treinado do DeepPrint, disponibilizado por Rohwedder et al. (2023), que pode ser obtido através do link[2]. O repositório com o código-fonte utilizado para o treinamento do modelo está disponível públicamente no GitHub[3]. A seguir serão descritos como foi feito treinamento o do modelo e os testes realizados.

4.4.1 Treinamento do DeepPrint

Engelsma, Cao e Jain (2021) utilizaram o conjunto de dados longitudinal (YOON; JAIN, 2015) de cerca de 455000 imagens de 38291 dedos, que não está disponível publicamente. Os autores não disponibilizaram nenhum código-fonte ou modelo pré-treinado. Dessa forma, optamos por utilizar a implementação da arquitetura do DeepPrint e modelo pré-treinado de Rohwedder et al. (2023), que tinha como objetivo avaliar o desempenho preditivo do modelo em imagens coletadas com outros tipos de sensores e com representações de tamanhos diferentes.

Com o intuito de eliminar a necessidade de coletar impressões digitais ou de utilizar um conjunto de dados público os autores utilizaram o SFinGe (MALTONI et al., 2022) para a criação de impressões digitais sintéticas. Para o treinamento, foram utilizadas 10 impressões digitais de 6000 indivíduos, e para validação 4 imagens de 2000 indivíduos, totalizando 68000 imagens. A partir deste banco de imagens foram geradas novas imagens aplicando-se rotações, reflexões e variações de brilho e contraste de forma aleatória, assim como no artigo original. Uma outra diferença em relação ao experimento de Engelsma, Cao e Jain (2021) foi o tamanho

[2] <https://drive.google.com/file/d/1R9v73hFBuy0iihz7v8eDlBcGrMDmQ9TH/view?usp=drive_link>
[3] <https://github.com/tim-rohwedder/fixed-length-fingerprint-extractors>

da representação. O modelo pré-treinado gera representações de 512 dimensões, com 256 de dimensões em cada sub-rede.

4.4.2 Testes com o modelo pré-treinado

Até o momento foram realizados testes utilizando os conjuntos de dados do FVC2004. São 4 conjuntos de imagens divididos em parte A com 800 imagens (100 dedos com 8 impressões cada) e parte B com 80 imagens (10 dedos com 8 impressões cada).. Para aumentar a acurácia do modelo as imagens passaram por um refinamento utilizando filtros de Gabor (KARIMIMEHR; BEHESHTI; BAHAGHIGHAT, 2010) e redimensionamento para o tamanho adequado para a CNN.

Em seguida, as imagens são processadas pelo modelo pré-treinado, que extrai os vetores de características de ambas as sub-redes, e a similaridade por cossenos é utilizada para calcular uma pontuação. A imagem de cada dedo é comparada com as demais imagens do mesmo dedo e com todas as imagens outros dedos.

Para calcular a FNMR, FMR e EER é necessário definir um limiar de corte que a pontuação deve atingir. Foram testados os valores $[.5, .55, .6, .65, .7, .75, .8, .85, .9, .95]$.

5 Resultados e discussão dos resultados

Na Tabela **??** é mostrada a ERR obtida com o FVC2004.

	Parte A	Parte B
DB 1	0.179	0.156
DB 2	0.056	0.111
DB 3	0.043	0.020
DB 4	0.126	0.059

Na Figura 2 são exibidas as curvas que relacionam a FMR e FNMR com os valores de limiar de corte escolhidos. Quando o valor de limiar de corte em que as curvas se cruzam é selecionado as taxas se igualam.

6 Conclusões e perspectivas de trabalhos futuros

Neste trabalho foi feita uma revisão bibliográfica na área de impressões digitais e técnicas de extração de características para verificação e avaliação de um modelo pré-treinado que extrai uma representação de tamanho fixo, que pode ser utilizada para autenticação de usuários.

No restante do projeto serão avaliados outras técnicas de extração de características, como o *FingerNet* e o *MinutiaeNet*, e outras que forem encontradas, incluindo o treinamento com os conjuntos de dados encontrados.

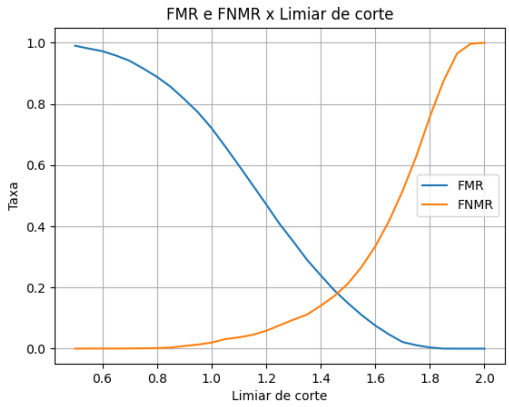

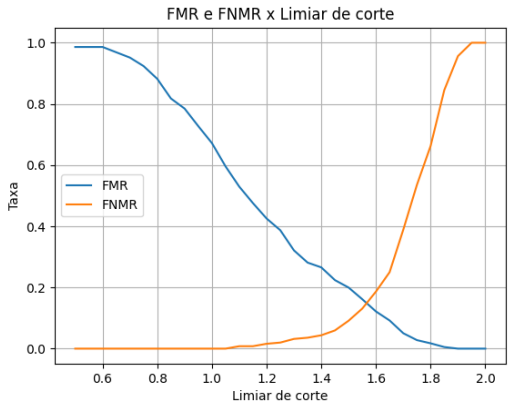

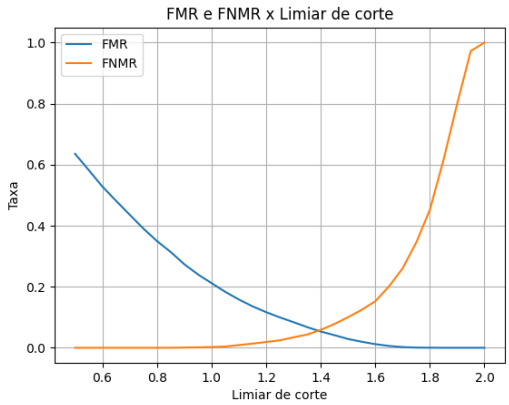

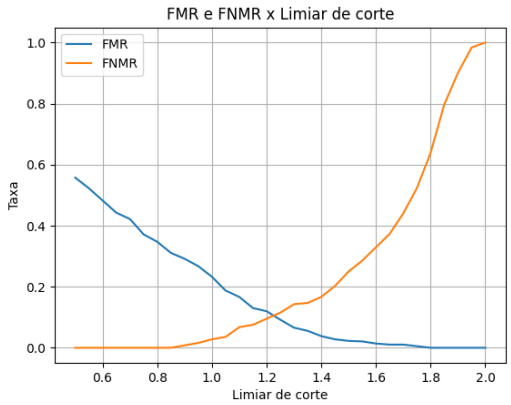

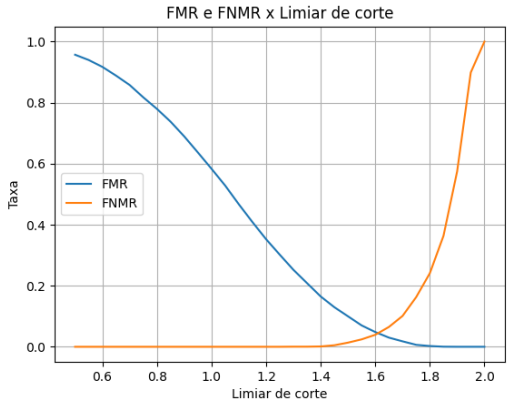

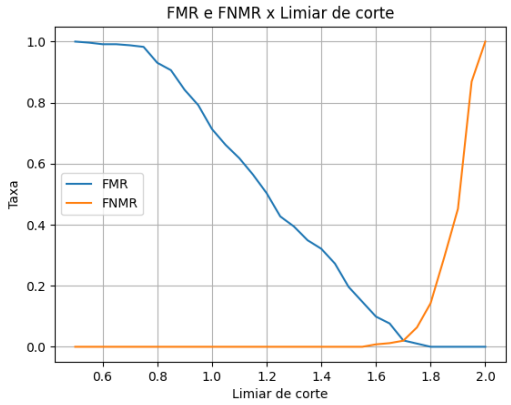

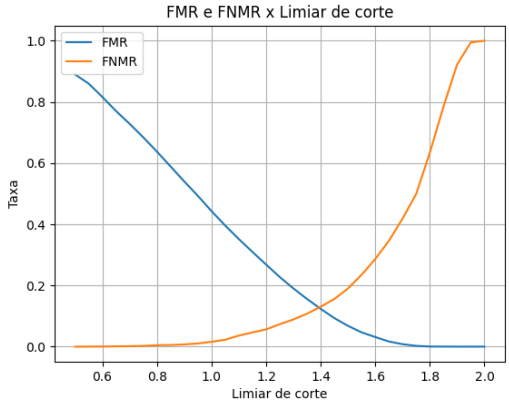

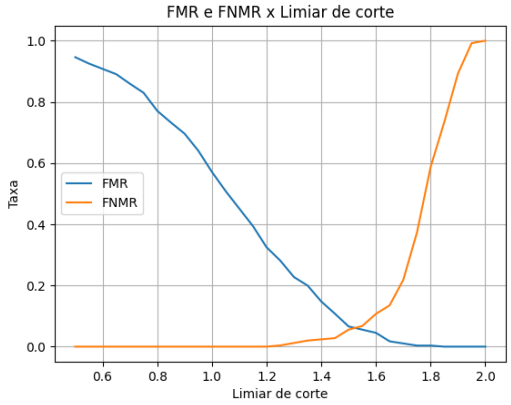

Parte A

Parte B

Figura 2 – FMR e FNMR - FVC2004

Referências

CAPPELLI, R.; FERRARA, M.; MALTONI, D. Minutia cylinder-code: A new representation and matching technique for fingerprint recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 32, p. 2128–2141, 2010. ISSN 01628828.

CARUANA, R.; PRATT, L.; THRUN, S. *Multitask Learning*. [S.l.], 1997. v. 28, 41-75 p.

ENGELSMA, J. J.; CAO, K.; JAIN, A. K. Learning a fixed-length fingerprint representation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, IEEE Computer Society, v. 43, p. 1981–1997, 6 2021. ISSN 19393539.

EZEOBIEJESI, J.; BHANU, B. Latent fingerprint image segmentation using deep neural network. In: _____. *Advances in Computer Vision and Pattern Recognition*. [S.l.]: Springer London, 2017. PartF1, p. 83–107.

FERLINI, A.; MA, D.; HARLE, R.; MASCOLO, C. Eargate: gait-based user identification with in-ear microphones. In: . New York, NY, USA: Association for Computing Machinery, 2021. (MobiCom '21), p. 337–349. ISBN 9781450383424.

JADERBERG, M.; SIMONYAN, K.; ZISSERMAN, A.; KAVUKCUOGLU, K. Spatial transformer networks. 2 2016. Disponível em: <http://arxiv.org/abs/1506.02025>.

JAIN, A.; FLYNN, P.; ROSS, A. *Handbook of Biometrics*. [S.l.]: Springer US, 2007. ISBN 9780387710419.

JAIN, A.; ROSS, A.; PANKANTI, S. Biometrics: a tool for information security. *IEEE Transactions on Information Forensics and Security*, v. 1, n. 2, p. 125–143, 2006.

JAIN, A.; ROSS, A.; PRABHAKAR, S. An introduction to biometric recognition. *IEEE Transactions on Circuits and Systems for Video Technology*, IEEE, v. 14, n. 1, p. 4–20, 2004. ISSN 1051-8215.

KARIMIMEHR, N.; BEHESHTI, S. A. A.; BAHAGHIGHAT, M. Fingerprint image enhancement using gabor wavelet transform. In: . [S.l.: s.n.], 2010. p. 316–320. ISBN 978-1-4244-6760-0.

LEVI, G.; SIROVICH, F. Structural descriptions of fingerprint images. *Information Sciences*, v. 4, n. 3, p. 327–355, 1972. ISSN 0020-0255. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0020025572800203>.

LI, R.; SONG, D.; LIU, Y.; FENG, J. Learning global fingerprint features by training a fully convolutional network with local patches. In: *2019 International Conference on Biometrics (ICB)*. [S.l.: s.n.], 2019. p. 1–8.

MALTONI, D.; MAIO, D.; JAIN, A. K.; FENG, J. Book. *Handbook of fingerprint recognition: Third edition*. [s.n.], 2022. 1 - 522 p. Cited by: 42. Disponível em: <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85159134415&doi=10.1007%2f978-3-030-83624-5&partnerID=40&md5=20c90152518eac119f092021f0fe4dfa>.

MOENSSENS, A. *Fingerprint Techniques*. Chilton Book Company, 1971. (Inbau law enforcement series). ISBN 9780801955273. Disponível em: <https://books.google.com.br/books?id=aF6qQgAACAAJ>.

NGUYEN, D. L.; CAO, K.; JAIN, A. K. Robust minutiae extractor: Integrating deep networks and fingerprint domain knowledge. In: *Proceedings - 2018 International Conference on Biometrics, ICB 2018*. [S.l.]: Institute of Electrical and Electronics Engineers Inc., 2018. p. 9–16. ISBN 9781538642856.

Precise Biometrics. *Understanding Biometric Performance Evaluation*. 2014. Disponível em: <http://precisebiometrics.com/wp-content/uploads/2014/11/White-Paper-Understanding-Biometric-Performance-Evaluation.pdf>.

ROHWEDDER, T.; OSORIO-ROIG, D.; RATHGEB, C.; BUSCH, C. Benchmarking fixed-length fingerprint representations across different embedding sizes and sensor types. In: *BIOSIG 2023 - Proceedings of the 22nd International Conference of the Biometrics Special Interest Group*. [S.l.]: Institute of Electrical and Electronics Engineers Inc., 2023. ISBN 9798350336559.

ROY, S.; PRADHAN, J.; KUMAR, A.; ADHIKARY, D. R. D.; ROY, U.; SINHA, D.; PAL, R. K. A systematic literature review on latest keystroke dynamics based models. *IEEE Access*, v. 10, p. 92192–92236, 2022.

SCOTT, W. *Fingerprint Mechanics: A Handbook; Fingerprints from Crime Scene to Courtroom*. Thomas, 1951. Disponível em: <https://books.google.com.br/books?id=zMA1AAAAIAAJ>.

SZEGEDY, C.; IOFFE, S.; VANHOUCKE, V.; ALEMI, A. Inception-v4, inception-resnet and the impact of residual connections on learning. *Proceedings of the AAAI Conference on Artificial Intelligence*, v. 31, n. 1, Feb. 2017. Disponível em: <https://ojs.aaai.org/index.php/AAAI/article/view/11231>.

TANG, Y.; GAO, F.; FENG, J. Latent fingerprint minutia extraction using fully convolutional network. In: *2017 IEEE International Joint Conference on Biometrics (IJCB)*. [S.l.: s.n.], 2017. p. 117–123.

TANG, Y.; GAO, F.; FENG, J.; LIU, Y. Fingernet: An unified deep network for fingerprint minutiae extraction. In: *2017 IEEE International Joint Conference on Biometrics (IJCB)*. [S.l.: s.n.], 2017. p. 108–116.

YOON, S.; JAIN, A. K. Longitudinal study of fingerprint recognition. *Proceedings of the National Academy of Sciences*, v. 112, n. 28, p. 8555–8560, 2015. Disponível em: <https://www.pnas.org/doi/abs/10.1073/pnas.1410272112>.

ZHANG, F.; XIN, S.; FENG, J. Combining global and minutia deep features for partial high-resolution fingerprint matching. *Pattern Recognition Letters*, v. 119, p. 139–147, 2019. ISSN 0167-8655. Deep Learning for Pattern Recognition. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0167865517303227>.